



# Classez des images à l'aide d'algorithmes de Deep Learning

Openclassroom

29 août 2022





# Présentation du projet :

## Objectif:

Développer un algorithme capable de classer les images en fonction de la race du chien présent sur l'image.

Cet objectif peut se rapprocher d'une tâche de classification multi class supervisée.

## Données:

Utilisation de données présentes sur [Vision Stanford](#).

Comprenant les images de chien classé par race dans différents dossiers.



# Données

Il y a 120 races représentées avec un total de 20 430 d'images.

Chaque dossier correspond à une race de chien particulière avec un ID unique.

- 📁 n02085620-Chihuahua
- 📁 n02085782-Japanese\_spaniel
- 📁 n02085936-Maltese\_dog
- 📁 n02086079-Pekinese
- 📁 n02086240-Shih-Tzu
- 📁 n02086646-Blenheim\_spaniel
- 📁 n02086910-papillon
- 📁 n02087046-toy\_terrier
- 📁 n02087394-Rhodesian\_ridgeback
- 📁 n02088094-Afghan\_hound



# Analyse exploratoire

Visualisation univariée



# Exemple d'image

n02086079-Pekinese



n02086079-Pekinese



n02086079-Pekinese



n02086079-Pekinese





# Preprocessing

normalisation, sélection de donnée et encodage

cv2, encoder

# Normalisation, selection and Encoding

```
le = LabelEncoder()

def get_training(nb_class):
    X = list()
    Z = list()

    def make_train_data(breed_name, DIR):
        for img in tqdm(os.listdir(DIR)):
            path = os.path.join(DIR, img)
            img = cv2.imread(path, cv2.IMREAD_COLOR)
            img = cv2.resize(img, (IMG_SIZE, IMG_SIZE))
            X.append(np.array(img))
            Z.append(str(breed_name))

    for breed in breed_list[:nb_class]:
        name = breed.split('-')[-1]
        img_dir = f"{IMAGES_DIR}/{breed}/"
        make_train_data(name, img_dir)

    # converting labels to categorical data
    Y = le.fit_transform(Z)
    Y = to_categorical(Y, nb_class)

    # Normalising X
    X = np.array(X) #.reshape(-1, IMG_SIZE, IMG_SIZE, 3)
    X = X.astype('float32')
    X = X/255

    return X, Y
```





# Data augmentation

Rotation, Equalization, whitening

ImageDataGenerator, exposure




# ImageDataGenerator

```
datagen = ImageDataGenerator(  
    featurewise_center=False, # set input mean to 0 over the dataset  
    samplewise_center=False, # set each sample mean to 0  
    featurewise_std_normalization=False, # divide inputs by std of the dataset  
    samplewise_std_normalization=False, # divide each input by its std  
    zca_whitening=False, # apply ZCA whitening  
    rotation_range=10, # randomly rotate images in the range (degrees, 0 to 180)  
    zoom_range = 0.1, # Randomly zoom image  
    width_shift_range=0.2, # randomly shift images horizontally (fraction of total width)  
    height_shift_range=0.2, # randomly shift images vertically (fraction of total height)  
    horizontal_flip=True, # randomly flip images  
    vertical_flip=False) # randomly flip images  
  
datagen.fit(x_train)
```

# Expansion de contraste (contrast stretching)

L'expansion de contraste est une méthode data augmentation qui permet d'améliorer le contraste d'une image en étendant l'intervalle d'intensité des valeurs qu'il contient.



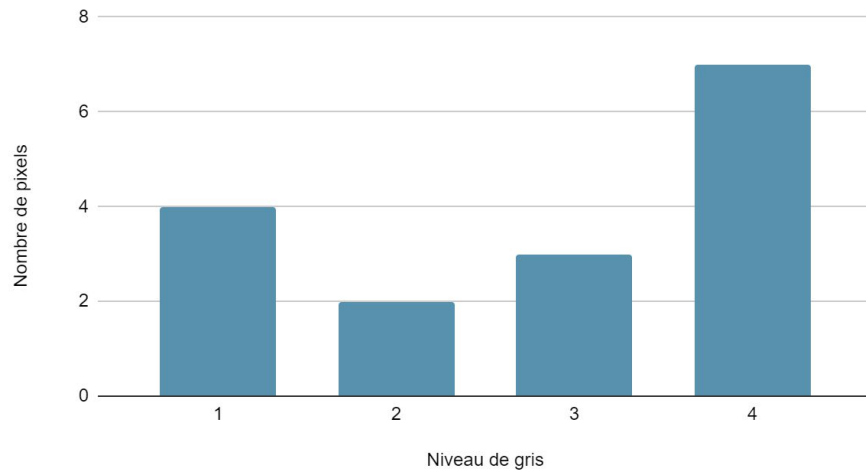
# Création histogramme

Histogramme par niveau de gris d'une image

Valeur niveau de gris  
image 4x4

1	2	3	4
1	2	4	4
1	3	4	4
1	3	4	4

Nombre de pixels par rapport au niveau de gris




Niveau de gris	1	2	3	4
Nombre de pixels	4	2	3	7

# Égalisation d'histogramme

Proportion de niveau de gris par rapport à l'histogramme cumulé

$$\forall v \in [0..n], eg(v) = \frac{V_{max} - V_{min}}{N} C_f(v) + V_{min}$$




La transformation T permet d'égaliser l'histogramme et d'améliorer le contraste.

Source : [Wikipédia](https://fr.wikipedia.org/wiki/%C3%89galisation_d%27histogramme)




image originale



Son histogramme (rouge) et l'histogramme cumulé (noir)



L'image après égalisation d'histogramme




L'histogramme (rouge) et l'histogramme cumulé (noir) après égalisation

Source : [Wikipédia](https://fr.wikipedia.org/wiki/%C3%89galisation_d%27histogramme)

# Égalisation adaptative d'histogramme

Le principe de cette méthode est d'appliquer une égalisation d'histogramme, sur des régions, ce qui donne du contexte à l'application.



# Égalisation avec ImageDataGenerator

Création de 3 méthodes personnalisées  
pour ImageDataGenerator

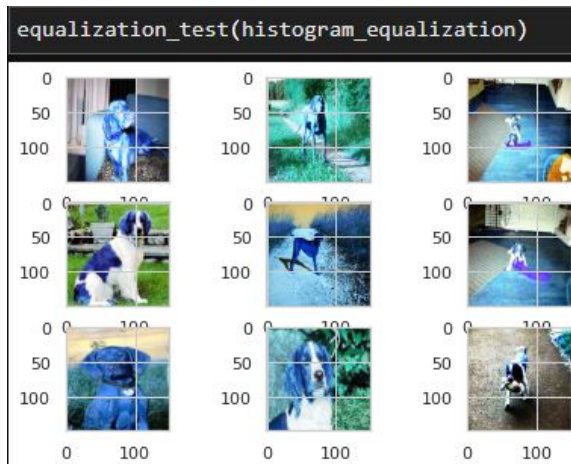
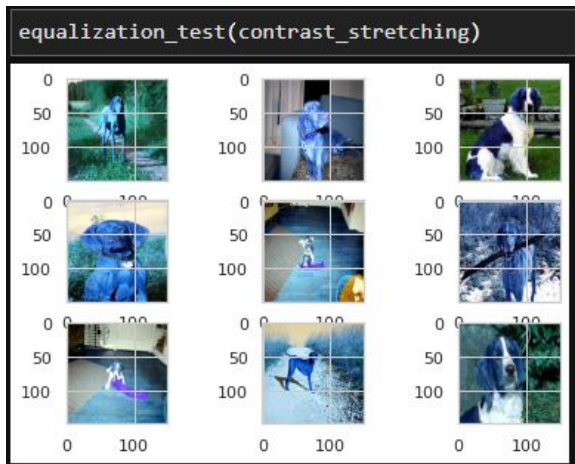
```
def AHE(img):
    img_adapteq = exposure.equalize_adapthist(img, clip_limit=0.03)
    return img_adapteq

def histogram_equalization(img):
    img_adapteq = exposure.equalize_hist(img) #####
    return img_adapteq

def contrast_stretching(img):
    p2, p98 = np.percentile(img, (2, 98)) #####
    img_adapteq = exposure.rescale_intensity(img, in_range=(p2, p98)) #####
    return img_adapteq

def equalization_test(fct):
    datagen_equalize = ImageDataGenerator(preprocessing_function=fct)
    x_ex, y_ex = x_train[:10], y_train[:10]
    # fit parameters from data
    datagen_equalize.fit(x_ex)
    img_rows, img_cols = 150, 150
    # Configure batch size and retrieve one batch of images
    for X_batch, y_batch in datagen_equalize.flow(x_ex, y_ex, batch_size=9):
        # Show 9 images
        for i in range(0, 9):
            plt.subplot(330 + 1 + i)
            plt.imshow(X_batch[i].reshape(img_rows, img_cols, 3))
        # show the plot
        plt.show()
        break
```

## Exemple d'application :







# Modèle CNN

Utilisation de méthode de Convolutional Neural Network

Implémentation faite avec Keras

# Présentation du modèle

```
model = Sequential()
model.add(Conv2D(filters = 32, kernel_size = (5,5), padding = 'Same', activation = 'relu', input_shape = (IMG_SIZE, IMG_SIZE, 3)))
model.add(MaxPooling2D(pool_size=(2,2)))

model.add(Conv2D(filters = 64, kernel_size = (3,3), padding = 'Same', activation = 'relu'))
model.add(MaxPooling2D(pool_size=(2,2), strides=(2,2)))

model.add(Conv2D(filters = 96, kernel_size = (3,3), padding = 'Same', activation = 'relu'))
model.add(MaxPooling2D(pool_size=(2,2), strides=(2,2)))


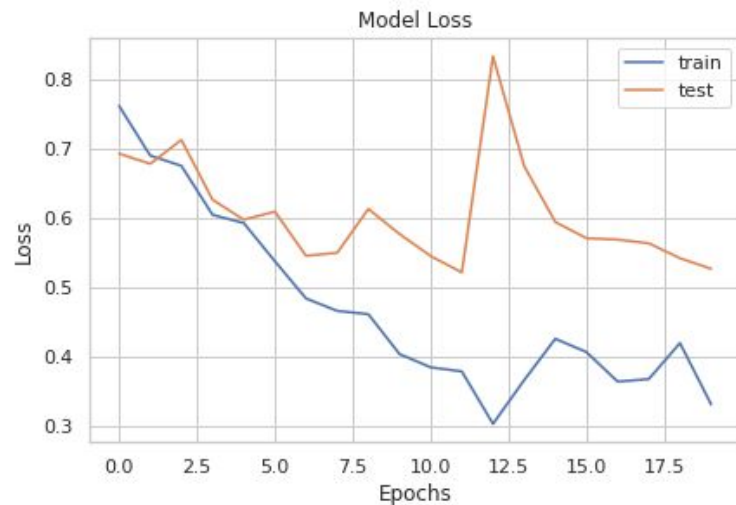
model.add(Conv2D(filters = 96, kernel_size = (3,3), padding = 'Same', activation = 'relu'))
model.add(MaxPooling2D(pool_size=(2,2), strides=(2,2)))

model.add(Flatten())
model.add(Dense(512))
model.add(Activation('relu'))
model.add(Dense(nb_class, activation = "softmax"))
```





Model: "sequential"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 150, 150, 32)	2432
max_pooling2d (MaxPooling2D)	(None, 75, 75, 32)	0
conv2d_1 (Conv2D)	(None, 75, 75, 64)	18496
max_pooling2d_1 (MaxPooling2D)	(None, 37, 37, 64)	0
conv2d_2 (Conv2D)	(None, 37, 37, 96)	55392
max_pooling2d_2 (MaxPooling2D)	(None, 18, 18, 96)	0
conv2d_3 (Conv2D)	(None, 18, 18, 96)	83040
max_pooling2d_3 (MaxPooling2D)	(None, 9, 9, 96)	0
flatten (Flatten)	(None, 7776)	0
dense (Dense)	(None, 512)	3981824
activation (Activation)	(None, 512)	0
dense_1 (Dense)	(None, 2)	1026
Total params: 4,142,210		
Trainable params: 4,142,210		
Non-trainable params: 0		

# Evaluation modèle



# Test du modèle





# Transfer Learning

Gagner en ressource et efficacité



# Modèle DenseNet

Utilisation de modèle pré entraîné de ImageNet

Sequential





# Présentation du modèle

# Explication rapide de DenseNet

Model: "sequential"

Layer (type)	Output Shape	Param #
conv2d (Conv2D)	(None, 150, 150, 32)	2432
max_pooling2d (MaxPooling2D)	(None, 75, 75, 32)	0
conv2d_1 (Conv2D)	(None, 75, 75, 64)	18496
max_pooling2d_1 (MaxPooling2D)	(None, 37, 37, 64)	0
conv2d_2 (Conv2D)	(None, 37, 37, 96)	55392
max_pooling2d_2 (MaxPooling2D)	(None, 18, 18, 96)	0
conv2d_3 (Conv2D)	(None, 18, 18, 96)	83040
max_pooling2d_3 (MaxPooling2D)	(None, 9, 9, 96)	0
flatten (Flatten)	(None, 7776)	0
dense (Dense)	(None, 512)	3981824
activation (Activation)	(None, 512)	0
dense_1 (Dense)	(None, 2)	1026
Total params: 4,142,210		
Trainable params: 4,142,210		
Non-trainable params: 0		

# Evaluation modèle







# Présentation application Flask